

题目（中英文题目一致）字体为 2 号黑体（全文除特别声明外，外文统一用 Times New Roman）

作者名¹⁾ 作者名^{2),3)} 作者名^{3)(*} 字体为 3 号仿宋 * 作者)*

¹⁾(单位全名部门(系)全名,市(或直辖市)国家名邮政编码)* 字体为 6 号宋体 * 单位

²⁾(单位全名部门(系)全名,市(或直辖市)国家名邮政编码)* 中英文单位名称、作者姓名须一致 *

³⁾(单位全名部门(系)全名,市(或直辖市)国家名邮政编码)

论文定稿后,作者署名、单位无特殊情况不能变更。若变更,须提交签章申请,国家为中国可以不写,省会城市不写省名,其他国家必须写国家名。

摘要 在预测服务市场中,模型训练者需要从数据拥有者处购买数据,随后训练机器学习服务模型,并为服务定价作为商品出售给模型使用者。现有市场为了激励数据所有者参与交易,允许数据拥有者将扰动后的数据售予服务提供者,同时为服务提供者提供可选的扰动认证服务,以减少数据拥有者添加过量扰动的可能性。现有的预测服务定价方法并未考虑服务提供者与数据拥有者关于数据扰动认证的博弈。本文研究了基于机器学习的预测服务在恶意扰动下的利润最大化定价问题,综合考虑了需求多样性和隐私保护性。首先推导了服务提供者在可认证扰动下的最优解,然后开发了基于利润比保障的有效框架以解决信息不完全的优化问题。该框架不仅能高效获得收益损失有界的次优服务价格,还能通过最大似然估计有效估计服务质量函数。基于真实数据集的实验表明,相较于现有最优方法,我们的工作在理论验证和实际效能方面均表现出显著优势。

关键词 数据交易; 利润最大化; 非完全信息博弈; 可验证性需求; 隐私保护

中图法分类号 TP DOI 号: * 投稿时不提供 DOI 号

Title * (中英文题目一致) 字体为 4 号 Times New Roman, 加粗 * Title

NAME Name-Name¹⁾ NAME Name²⁾ NAME Name-Name³⁾ * 字体为 5 号 Times new Roman*Name

¹⁾(Department of *****, University, City ZipCode, China)* 字体为 6 号 Times new Roman* Depart.Correspond

²⁾(Department of *****, University, City ZipCode)* 中国不写国家名 *

³⁾(Department of *****, University, City ZipCode, country)* 外国写国家名 *

Abstract In the prediction service market, model trainers need to purchase data from data owners, train machine learning service models, and price the services as commodities for sale to model users. Existing markets incentivize data owners to participate by allowing them to sell perturbed data to service providers while offering optional perturbation verification services to reduce the likelihood of data owners adding excessive perturbations. Current prediction service pricing methods do not account for the game-theoretic interactions between service providers and data owners regarding data perturbation verification. This paper studies the profit-maximization pricing problem for machine learning-based prediction services under malicious perturbations, jointly considering diverse demand and privacy

收稿日期: - - ; 最终修改稿收到日期: - - . 投稿时不填写此项 *. 本课题得到……基金中文完整名称(No. 项目号)、……基金中文完整名称(No. 项目号)、……基金中文完整名称(No. 项目号)资助. 作者名 1(通信作者), 性别, xxxx 年生, 学位(或目前学历), 职称, 是/否计算机学会(CCF)会员(提供会员号), 主要研究领域为 *****, **** E-mail: *****. 作者名 2(通信作者), 性别, xxxx 年生, 学位(或目前学历), 职称, 是/否计算机学会(CCF)会员(提供会员号), 主要研究领域为 *****, ****. E-mail: *****. 作者名 3(通信作者), 性别, xxxx 年生, 学位(或目前学历), 职称, 是/否计算机学会(CCF)会员(提供会员号), 主要研究领域为 *****, ****. E-mail: *****. (给出的电子邮件地址应不会因出国、毕业、更换工作单位等原因而变动。请给出所有作者的电子邮件) 第 1 作者手机号码(投稿时必须提供,以便紧急联系,发表时会删除): ……, E-mail:* 此部分 6 号宋体 *

preservation. We first derive the optimal solution for service providers under verifiable perturbations, then develop an effective framework with a profit ratio guarantee to address the optimization problem under incomplete information. This framework not only efficiently obtains sub-optimal service prices with bounded revenue loss but also accurately estimates the service quality function via maximum likelihood estimation. Experiments on real-world datasets demonstrate that, compared to state-of-the-art methods, our work achieves significant advantages in both theoretical validation and practical efficiency.

Keywords Data trading; profit maximization; incomplete information; availability requirement; privacy preserved.

1 引言

数据与数据驱动的服务在各领域具有广泛的运用，尤其是数据驱动的预测服务，包括股票预测、图像识别等。其具有零知识服务特性，意即使用者可以在不具备计算资源，不掌握机器学习的知识的前提下能使用预测服务。相较于传统的机器学习应用更加经济和方便。因此使用基于机器学习的预测服务市场欣欣向荣。

为了进行预测服务，服务提供者需要从数据拥有者处购买数据，使用数据训练机器学习模型，并将模型作为服务出售。期间服务提供者需要决定购买的数据量，测试模型的质量，为机器学习模型的服务定价，以获取最高的利润。

然而在购买数据时，服务提供者不知道所购买的数据对模型的预测结果有何影响，数据拥有者也没动机公布数据质量，市场中也存在不同类型的服务购买者。除此之外，数据拥有者提供的数据可能包含隐私，不能直接用这种隐私数据训练服务模型。

为了解决数据隐私的问题，可以使用基于查询的数据出售方案进行数据交易。基于查询的数据出售方式能支持广泛的运用途径，适合不同场景下的模型训练问题，同时支持订制数据的准确性与隐私性，能让训练师有所选择，保持平衡。该技术通过在原始数据中添加扰动，使用差分隐私等手段保护数据拥有者的隐私。在基于查询的数据出售方案中，服务提供者决定所购买数据的精密度系数，数据拥有者根据精密度系数选择所添加的扰动和收取的费用，在为原始数据添加扰动后，将扰动后数据发送给服务提供者。

添加扰动的方法有两种，一种是请可信第三方添加，另一种是让数据拥有者自行添加。可信第三方难以找到，而且费用很高。倘若让数据拥有者去添加噪声的话，拥有者有动机去添加过量噪声，保护自己隐私的同时减少了服务提供者训练的模型质量，损害了服务提供者的利益。

因此在基于查询的数据出售方案中引入了基于同态加密的认证系统。若数据拥有者提供的数据相当可疑，服务提供者可以对该数据发起认证。一旦发起认证，借助引入诚实但好奇的第三方，服务提供者便可以得知数据拥有者是否添加了过量扰动，若添加了过量扰动，数据拥有者便需要为自己的恶意行为赔偿服务提供者。若数据拥有者没有添加过量扰动，则其数据隐私遭到泄露，服务提供者需要为认证过程赔偿数据拥有者。

因此，本文首次考察了在可认证的隐私保护的，有不同种类的服务购买方的不完全信息的数据市场，主要贡献如下所示：1、我们是第一个考虑服务市场模型中存在恶意扰动者。2、我们对一个三方市场进行建模，考察其中各个角色的需求与行动，并定量分析他们的最优策略为何。3、我们设计了一套行之有效的市场机制，能保证数据拥有者倾向于按照协议添加扰动。同时市场机制满足个体理性、群体理性和免套利性。

2 相关工作

2.1 数据定价

较低的出售价格能吸引更多的买家，而更高的售价可以提升单件物品的利润，该如何平衡两者以

获得最高收入? 收入最大化, 又称利润最大化问题, 是传统经济学与博弈论领域已得到充分研究的问题, 其一大成果便是数据定价。瓦尔拉斯均衡解决了完全竞争市场中卖家的收入最大化问题, 单边拍卖也能从购买方角度提供解决方案。然而以上工作基于边际效益, 数字产品具有边际成本近乎为零的特点, 其复制成本低廉的特性使得大数据能免费传播。原则上而言, 最有效的数据交易价格就是零, 这使得以上的定价方案在数据市场中均不适用 [14]。

已有的数据定价方案较为零散, 适用于不同的场景, 包括 SQL 查询 [12][13][14]、线性统计 (linear aggregate query) 模型 [15][16][17][18]、机器学习模型 [19][20]、机器学习分类 [21][22]、物联网数据等 [23]。这些工作缺少利润的定量计算与优化, 或者对市场的信息透明度有着强假设, 因此不适用于我们的场景。

2.2 代理人模式

使用经典的委托-代理人模式, 由 [1] 首次提出, 假设数据代理人 (data agent) 是可信的第三方, 让出售者提交数据, 代理人扰动数据以达到免套利的效果。在这个机制中, 数据购买方向数据拥有者的隐私进行赔偿后便可以计算添加的扰动多寡, 从而对扰动的合法性发出质疑。当数据拥有者提高扰动时, 能减少自己的隐私损失, 同时让数据的可用性降低, 因此能相应减少数据的价格, 以增加销量。这就构成了一个多变量优化问题。之后有许多工作试图解决该优化问题以最大化代理人的收益, [2] 的工作大多基于公开信息博弈, 假设代理人知道数据拥有者的损失函数进行优化, [3] 则取消了上述限制, 根据之前的交易结果推断下次交易时的策略。再者, 数据之间通常并非独立的, 而是有一定的相关性, 相关数据的隐私分析更为困难。为了解决上述问题, [5][6] 引入了差分隐私技术, 计算数据拥有者的隐私损失, 并在时序数据市场 [7]、关联子查询数据市场 [8] 等领域进行考察, 在最大化数据代理人 t 的收益的基础上保护数据拥有者的隐私。

2.3 数据拥有者模式

在实际操作中, 一个完全可信的第三方难以寻找且代价太高 [9], 因此出现了由数据拥有者自行添加扰动的出售模式。[10] 假设数据使用者和数据拥有者是商业联盟, 并计算合适的隐私以最大化双方收益总和。然而市场中数据拥有者和数据使用者实际上是对立关系, 数据拥有者有动机添加过量扰动, 从而保护自己的隐私, 对数据使用者而言则减少了数据可用性 [9]。为了让数据拥有者能按照协议添加合适的扰动, 需要为数据拥有者引入负反馈机制, 即允许数据使用者对数据进行质疑。然而在数据交易市场中, 数据使用者无法获得未扰动的原始数据, 使得质疑困难重重。

3 市场模型

3.1 可认证扰动

对于 ϵ -差分隐私而言, 其渐近误差边界与 $\frac{1}{\epsilon}$ 成正比, 与模型的训练时长 $\frac{1}{n^{0.5}}$ 成正比^[1]。

本文所考虑的模型如上图所示, 其创新点在于考察了预测模型市场中, 数据拥有者可能存在的造假问题。模型一共包含 4 方角色, 分别是数据拥有者 (Data Seller)、服务提供者 (Service Provider) 以及服务消费者 (Service Consumers) 以及第三方 (Third Party)。

在服务提供者向数据拥有者购买数据的过程中, 服务提供者需要决定所购买的数据的隐私扰动系数 ϵ , 使用同态加密技术生成公钥 pk 和私钥 sk , 并公布公钥 pk 。第三方随即根据隐私扰动系数 ϵ 生成相应强度的扰动 $\eta(\epsilon)$, 使用服务提供者的公钥加密得到 $pk(\eta(\epsilon))$, 并将其发送给数据拥有者。

数据拥有者接收 $pk(\eta(\epsilon))$ 后, 使用服务提供者的公钥加密数据商品 d_i 得到 $pk(d_i)$, 并决定此次交易使用的策略 s_{do_i} 选择添加的扰动量 ϵ 。若选择诚实策略 $s_{do_i}^h$, 则选择从第三方接收 $pk(\eta(\epsilon))$, 并使用同态加算法计算得到 $pk(d_i + \eta(\epsilon)) = pk(d_i) \oplus pk(\eta(\epsilon))$, 此时添加的扰动量 $\eta = \eta(\epsilon)$; 若选择恶意扰动策略, 则生成过量扰动 η_m , 使用服务提供者的公钥计算

$pk(\eta_m)$, 并使用同态加算法计算得到 $pk(d_i + \eta_m) = pk(d_i) \oplus pk(\eta_m)$, 此时添加的扰动量 $\eta = \eta_m$ 。并将 $pk(d_i + \eta(\epsilon))$ 发送给服务提供者。服务提供者接受密文后, 解密 $pk(d_i + \eta)$ 得到 $d_i + \eta$, 随即根据隐私扰动系数 ϵ , 向数据拥有者支付价格 $p_{do_i}(\epsilon)$, 并决定是否质疑数据拥有者添加了过量扰动. 如若决定质疑, 则向第三方发起认证要求。

当服务提供者发起认证要求之后, 第三方将扰动密文 $pk(\eta(\epsilon))$ 发送给服务提供者, 服务提供者解密得到 $\eta(\epsilon)$, 计算 $d_p = d_i + \eta - \eta(\epsilon)$, 计算其哈希值 $H(d_p)$, 并将 $H(d_p)$ 发送给第三方。同时服务提供者需要将数据原文的哈希值 $H(d_i)$ 发给第三方。第三方通过比较 $H(d_i)$ 和 $H(d_p)$ 是否相等, 就能判断数据提供方是否进行了恶意扰动。无论认证结果如何, 数据原文都会暴露给服务提供者。因此若数据提供方没有添加过量噪声, 质疑结果 $\phi = 0$, 服务提供方就需要给数据提供方补偿。反之, 若 $\phi = 1$, 数据提供方需要为自己的恶意扰动付出代价, 给服务提供方补偿。

若未发起认证或者数据拥有者没有添加恶意扰动, 服务提供者便使用密文训练模型, 评估模型质量 q , 提供预测服务, 并决定预测服务的价格 p 。

定义: 预测模型为了分析服务提供者训练预测模型的过程, 首先需要考察模型训练过程。给定数据集 S_i , 服务提供者使用该数据训练, 获取预测模型 $h(S_i)$ 。服务消费者给定数据 x , 模型 h 关于 x 的预测结果 $h(x)$ 的正确率为 $q_h(x)$ 。

为简洁起见, 我们记使用数据集 S_i 购买数据量 n_i 训练成的集合 $h(S_i)$ 的准确率为 $q(S_i)$ 。不失一般性, 假设训练用数据越多, 模型质量越好, 即 $q(x)$ 为关于 x 单调递增的函数, $q'(x) > 0$ 。由于模型质量关于训练用数据的边际效益递减, 当随着训练用数据规模的增大, 添加等量数据对模型质量的提升效果逐渐变小, 因此我们假设 $q''(x) < 0$ 。

文中记号	
* 记号 *	* 记号的含义 *
$DO=\{do_i\}_{i=1}^m$	数据拥有者
$SC=\{sc_j\}_{j=1}^n$	服务消费者
SP	服务提供者
ϵ	扰动系数
$p_{do_i}(\epsilon)$	数据拥有者 i 的要价
$g_{do_i}(\epsilon)$	数据拥有者 i 的隐私损耗
p	预测服务单价
$q_i(\epsilon)$	预测服务质量
$f_j(q)$	服务购买者 j 的收益
$d_j(q)$	服务购买者 j 的购买量

服务提供方完成训练后, 需要为机器学习服务进行定价, 确定单位服务的单价 p 。在本文中, 我们使用线性模型拟合服务提供者的收益于支付价格, 即服务消费者的收益与模型质量 q 成正比, 需要支付的价格与购买量 d 成正比。鉴于服务购买方的购买量和单价成反比, 服务提供方需要选取合适的价格 p , 以最大化其利润。

为了解决上述问题, 先考察服务消费者在给定服务单价下的策略, 为此需要分析其效用, 定义其效用函数 U_{sc_j} 如下:

$$U_{sc_j}(p, q, d) = q \cdot f_j(d, q) - p \cdot d \quad (1)$$

其中 $f_j()$ 为服务消费者 j 的效用函数, 体现了服务市场中 j 类型的服务消费者的市场特征。 d 为服务消费者 j 所购买的服务量, 购买 d 份量的服务后, j 的收益为 $q \cdot f_j(d, q)$ 。 p 为服务提供者设定的单位价格, 购买 d 份预测服务时需要向服务提供者支付 $p \cdot d$ 的费用。

可以看到, 当 f 和 p 给定时, c 为关于 d 的函数。如前文所述, 我们假设服务消费者的效用函数 a 均为凸函数, 那么 b 也是凸函数。由凸函数的性质可知, U_{sc_j} 达到最大值时当且仅当一阶导为零, 即满足:

$$q \cdot f'_j(d) - p = 0 \quad (2)$$

上式表明理性的服务购买者 j 所购买的服务数量 d_j 应如下所示:

$$d_j(p, q) = \max\{0, f_j'^{-1}(p/q)\} \quad (3)$$

可以推断出, 在模型质量为 q , 定价为 p 的情况下, 第 j 种数据购买方的所提供的交易额为 $p \cdot d_j$ 。设第 j 种服务消费者在市场中的占比为 π_j , 那么服务提供者的总收益为:

$$r_{SP}(p, q) = p \cdot \sum_j \pi_j \cdot d_j \quad (4)$$

下面考察数据拥有者和服务提供者的交易, 在数据市场中, 服务提供者在数据拥有者中挑选数据, 支付价格, 购买定量数据, 处于冲突状态。因此我们假设数据拥有者和服务提供者的交易遵循完全信息非合作博弈模型。该博弈模型要求参与者在进入市场时即公布自己的效用函数, 同时在知道对手效用函数的前提下, 以自身收益最大化为目标选择策略。下面分析数据拥有者和服务提供者的纯策略。

在数据市场博弈模型中, 数据拥有者可以选择诚实地添加扰动 ($s_{do_i}^h$), 或者恶意添加扰动 ($s_{do_i}^m$) 两种策略, 以下简记为 (h) 和 (m) 。服务提供者可以选择相信数据提供者诚实地添加扰动从而不采取认证 (s_{SP}^b), 或者质疑数据提供者添加过量扰动并采取认证 (s_{SP}^v) 两种策略, 以下简记为 (b) 和 (v) 。我们记数据拥有者的收益函数为 $u_{do_i}(x, y)$, 服务提供者的收益函数为 $u_{SP}(x, y)$, 其中 x 为数据拥有者的策略, y 为服务提供者的策略。数据拥有者采用诚实策略的概率为 $p_{do_i}^h$, 采用恶意扰动的概率为 $p_{do_i}^m$ 。服务提供者采用相信的概率为 p_{SP}^b , 采用质疑的概率为 p_{SP}^v 。

那么数据拥有者在服务提供者选择相信策略的收益为:

$$\begin{aligned} U_{do_i}(p_{do_i}, p_{SP}) &= p_{do_i}^h \cdot u_{do_i}(h, b) \\ &\quad + p_{do_i}^m \cdot u_{do_i}(m, s_{SP}^b) \end{aligned} \quad (5)$$

那么数据拥有者在服务提供者选择相信策略的收益为:

$$\begin{aligned} U_{do_i}(p_{do_i}, p_{SP}) &= p_{do_i}^h \cdot u_{do_i}(h, v) \\ &\quad + p_{do_i}^m \cdot u_{do_i}(m, s_{SP}^v) \end{aligned} \quad (6)$$

那么服务提供者在数据拥有者选择诚实扰动策略的收益为:

$$\begin{aligned} U_{SP}(p_{do_i}, p_{SP}) &= p_{SP}^b \cdot u_{SP}(h, b) \\ &\quad + p_{SP}^v \cdot u_{SP}(h, v) \end{aligned} \quad (7)$$

那么服务提供者在数据拥有者选择恶意扰动策略的收益为:

$$\begin{aligned} U_{SP}(p_{do_i}, p_{SP}) &= p_{SP}^b \cdot u_{SP}(h, b) \\ &\quad + p_{SP}^v \cdot u_{SP}(h, v) \end{aligned} \quad (8)$$

下面考察服务提供者和数据拥有者在纯策略下的效用 $u_{SP}(s_{do_i}, s_{SP})$ 和 $u_{do_i}(s_{do_i}, s_{SP})$, 我们记服务提供者的要价为 p_{do_i} , 记数据拥有者的隐私损耗 (privacy loss) 在扰动系数 ϵ 下为 $g(\epsilon)$, 那么有:

若数据拥有者选择诚实添加扰动, 服务提供者选择不发起认证质疑, 那么服务提供者依协议向数据拥有者支付购买费用, 而无需支付认证费用或者赔偿费用, 因此数据拥有者 i 的效用为:

$$u_{do_i}(h, b) = p_{do_i} - g(\epsilon) \quad (9)$$

服务提供者的效用为:

$$u_{SP}(h, b) = r_{SP}(p, q) - p_{do_i} \quad (10)$$

其中 $r_{SP}(p, q)$ 为服务提供者为服务消费者提供服务所获得的总收益。

若数据拥有者选择诚实添加扰动, 服务提供者选择发起认证质疑, 那么服务提供者依协议向数据拥有者支付购买费用, 还要支付赔偿费用, 因此数据拥有者 i 的效用为:

$$u_{do_i}(h, v) = p_{do_i} + c_{do_i} - g(0) \quad (11)$$

服务提供者的效用为:

$$u_{SP}(h, v) = r_{SP}(p, q) - p_{do_i} - c_{do_i} \quad (12)$$

其中 c_{do_i} 是服务提供者向数据拥有者 i 支付的费用。

若数据拥有者选择恶意添加过量扰动，服务提供者不选择发起认证质疑，那么服务提供者依协议向数据拥有者支付购买费用，还几乎不能获得收益，因为训练模型的数据被扰动了。在该情形下，数据拥有者 i 的效用为：

$$u_{do_i}(m, b) = p_{do_i} \quad (13)$$

服务提供者的效用为：

$$u_{SP}(m, b) = -p_{do_i} \quad (14)$$

若数据拥有者选择恶意添加过量扰动，服务提供者选择发起认证质疑，那么数据拥有者还需要向服务提供者支付赔偿。在该情形下，数据拥有者 i 的效用为：

$$u_{do_i}(m, v) = p_{do_i} - c_{SP} \quad (15)$$

服务提供者的效用为：

$$u_{SP}(m, v) = c_{SP} - p_{do_i} \quad (16)$$

其中 c_{SP} 为数据拥有者在添加恶意扰动并被服务提供者认证成功时，需要支付给服务提供者的补偿。

服务提供者采用相信策略的概率为 p_{SP}^b ，采用认证策略的概率为 p_{SP}^v ，那么数据拥有者的期望收益为：

$$U_{do_i} = \begin{cases} p_{SP}^b \cdot u_{do_i}(h, b) + p_{SP}^v \cdot u_{do_i}(h, v), S_{do_i} = h \\ p_{SP}^b \cdot u_{do_i}(m, b) + p_{SP}^v \cdot u_{do_i}(m, v), S_{do_i} = m \end{cases} \quad (17)$$

其中 h 意为数据拥有者采纳了诚实扰动策略， m 意为采纳了恶意扰动策略。

记数据拥有者采用诚实扰动的概率为 $p_{do_i}^h$ ，采用恶意扰动的概率为 $p_{do_i}^m$ ，那么服务提供者的期望收益为：

$$U_{SP} = \begin{cases} p_{do_i}^h \cdot u_{SP}(h, b) + p_{do_i}^m \cdot u_{SP}(m, b), S_{SP} = b \\ p_{do_i}^h \cdot u_{SP}(h, v) + p_{do_i}^m \cdot u_{SP}(m, v), S_{SP} = v \end{cases} \quad (18)$$

最后，我们考察数据拥有者和服务提供者的博弈达到纳什均衡的状态时的两者策略。此时无论服务提供者采用何种混合策略都不影响数据拥有者的效益，同时无论数据拥有者采用何种混合策略都不影响服务提供者的效益，因此有：

$$\begin{cases} u_{do_i}(S_{do_i} = s_{do_i}^h) = u_{do_i}(S_{do_i} = s_{do_i}^m) \\ u_{DC}(S_{DC} = s_{DC}^b) = u_{DC}(S_{DC} = s_{DC}^v) \end{cases} \quad (19)$$

可以得出数据拥有者的纳什均衡策略为：

$$\begin{cases} p_{do_i}^h = \frac{c_{SP}}{c_{SP} + c_{do_i}} \\ p_{do_i}^m = \frac{c_{do_i}}{c_{SP} + c_{do_i}} \end{cases} \quad (20)$$

特别地，在数据拥有者采用纳什均衡混合策略时，服务提供者的期望收益和纯策略相等，因此其期望收益为：

$$\begin{aligned} U_{SP}(p_{do_i}, p_{SP}) &= p_{do_i}^h \cdot u_{SP}(h, b) + p_{do_i}^m \cdot u_{SP}(m, s_{SP}^b) \\ &= \frac{c_{SP}(r_{SP} - p_{do_i}) - c_{do_i}p_{do_i}}{c_{SP} + c_{do_i}} \\ &= \frac{c_{SP}r_{SP}}{c_{SP} + c_{do_i}} - p_{do_i} \end{aligned} \quad (21)$$

接下来考察服务提供者的纳什均衡策略，此时有：

综上所述，在数据市场中，最大化服务提供者利润的优化模型如下所示：

令上式 = 0, 解得

$$\frac{c_{SP}r_{SP}}{c_{SP} + c_{do_i}} - p_{do_i} \quad (22)$$

其中:

$$r_{SP}(p, q) = p \cdot \sum_j \pi_j \cdot d_j \quad (23)$$

$$d_j(p, q) = \max\{0, f_j'^{-1}(p/q)\} \quad (24)$$

$$c_{do_i} \geq 0 \quad (25)$$

$$p_{do_i} \geq 0 \quad (26)$$

$$p \geq 0 \quad (27)$$

接下来对优化目标进行数学上的分析, 记 $C_{sp} = \eta \cdot do_i$, 得到:

$$U_{SP} = \frac{\eta}{\eta + 1} \cdot r_{SP} - p_{do_i} \quad (28)$$

注意到 $r_{SP} = p \cdot \sum_j \pi_j d_j$, $d_j = d_j(p, q) = d_j(\frac{p}{q}) = \max\{0, f_j'^{-1}(\frac{p}{q})\}$, $q = Q(p_{do_i})$. 得出 $p_{do_i} = Q^{-1}(q)$.

记 $\frac{p}{q} = x$, $D(\frac{p}{q}) = \sum_j \pi_j d_j = \sum_j \pi_j d_j(\frac{p}{q})$

我们得到 $r_{SP} = p \cdot D(x)$.

最后, 我们得出:

$$U_{SP} = \frac{\eta}{\eta + 1} x \cdot D(x) - Q^{-1}(q) \quad (29)$$

接下来分析上式, 由于 $Q^{-1''} = -\frac{Q''(x)}{Q'(x)^3}$, 且由于训练用数据对于模型质量的边际效益递减, $Q'(x) > 0$, $Q''(x) < 0$, 因此 $Q^{-1''} > 0$, 由此得出

$$\frac{dU}{dq} = \frac{\eta}{\eta + 1} x \cdot D(x) - Q^{-1'}(q) \quad (30)$$

接下来分析上式, 由于 $Q^{-1''} = -\frac{Q''(x)}{Q'(x)^3}$, 且由于训练用数据对于模型质量的边际效益递减, $Q'(x) > 0$, $Q''(x) < 0$, 因此 $Q^{-1''} > 0$, 由此得出 U_{SP} 在固定 x 时存在唯一极大值点。令 $\frac{dU}{dq} = 0$, 得到:

$$\frac{\eta}{\eta + 1} x \cdot D(x) - Q^{-1'}(q) = 0 \quad (31)$$

$$Q^{-1'}(q) = \frac{\eta}{\eta + 1} x \cdot D(x) \quad (32)$$

$$q = (Q^{-1'})^{-1}\left(\frac{\eta}{\eta + 1} x \cdot D(x)\right) \quad (33)$$

记 $y = \frac{\eta}{\eta + 1} x \cdot D(x)$, 有:

$$U_{SP} = q \cdot y - Q^{-1}(q) \quad (34)$$

且 $q = (Q^{-1'})^{-1}(y)$

那么 $y = Q^{-1'}(q)$, 又因为 $Q^{-1}(q) = p_{do_i}$,

$y = \frac{1}{f'(p_{do_i})}$, 因此 $p_{do_i} = Q'^{-1}(\frac{1}{y})$, 得出:

$$\begin{aligned} Q^{-1}(q) &= p_{do_i} = Q'^{-1}\left(\frac{1}{y}\right) \\ q &= Q(Q'^{-1}\left(\frac{1}{y}\right)) \end{aligned} \quad (35)$$

因此原式转换如下:

$$\begin{aligned} U_{SP} &= q \cdot y - Q^{-1}(q) \\ &= y \cdot Q(Q'^{-1}\left(\frac{1}{y}\right)) - Q'^{-1}\left(\frac{1}{y}\right) \end{aligned} \quad (36)$$

记 $z = Q'^{-1}\left(\frac{1}{y}\right)$, 那么 $\frac{1}{y} = Q'(z)$, $y = \frac{1}{Q'(z)}$, 有:

$$\begin{aligned} U &= \frac{1}{Q'(z)} Q(z) - z \\ U'(z) &= -\frac{Q''(z)}{Q'(z)^2} Q(z) \end{aligned} \quad (37)$$

由于 $Q(z) > 0$, $Q'(z) > 0$, $Q''(z) < 0$, 因此 $U'(z) > 0$ 恒成立, 因此求原式最大值等价于求 z 最大值

由于

$$D\left(\frac{p}{q}\right) = \sum_j \pi_j d_j = \sum_j \pi_j d_j\left(\frac{p}{q}\right) \quad (38)$$

$$d_j(p, q) = \max\{0, f_j'^{-1}(p/q)\} \quad (39)$$

可以看出 $D(z)$ 为分段函数, 在每个满足 $f_j'^{-1}(z) = 0$ 的 z 处分段, 不失一般性, 记 z_j 满足 $f_j'^{-1}(z_j) = 0$, 且 $z_1 \leq z_2 \leq \dots \leq z_n$, 那么由分段函数的性质, D 的最大值在 $Z = z_{j=1}^n$ 中取到, 或者在 $\arg_z \{z \cdot D'(z) + D(z) = 0\}$ 上取到, 那么只用考察这些特殊点即可, 为此我们引入如下算法以解决该问题。

算法 Y. PMCI 算法.

输入: 模型质量函数 $q(n)$; 不同服务购买者的收益函数 $f_j(q)$,

输出: 最佳购买量 p_{do_i} 和定价 p

1. 初始化空最小堆 EP
2. $R^* \leftarrow \Delta^* \leftarrow n^* \leftarrow \Delta_l \leftarrow 0$ // 初始化
3. FOREACH 服务消费者 j DO
 4. 计算其效用反函数 $f^{-1}(\Delta)$
 5. $\Delta_j \leftarrow f'_j(0)$; En-Heap(EP, Δ_j)
6. WHILE $EP \neq \emptyset$ DO:
 7. $\Delta_r \leftarrow \text{De-Heap}(EP)$
 8. 考察区间 $(\Delta_l, \Delta_r]$ 上的收益函数

$$D(\Delta) = \sum_{1 \leq j \leq M, \Delta_j > \Delta_l} f'^{-1}_j(\Delta)$$
 9. $R_{EP} \leftarrow \Delta_r \cdot D(\Delta_r)$
 10. IF $R_{EP} > R^*$ THEN
 11. $R^* \leftarrow R_{EP}; \Delta^* \leftarrow \Delta_r$
 12. 接下来计算满足 $D(\Delta) + \Delta \cdot D'(\Delta) = 0$ 的零点 Δ_c
 13. IF $\Delta_c < \Delta_r \& \Delta_c > \Delta_l$ THEN
 14. $R_c \leftarrow \Delta_c \cdot D(\Delta_c)$
 15. IF $R_c > R^*$ THEN
 16. $R^* \leftarrow R_c; \Delta^* \leftarrow \Delta_c$
 17. $\Delta_l \leftarrow \Delta_r$
 18. $n^* \leftarrow \arg_n\{q'(n) = c/R^*\}$
 19. $n \leftarrow \min\{\max\{n_l, n^*\}, 100\}$
 20. IF $q(n^*) \cdot R^* - n^* \cdot c < 0$ THEN
 21. $n^* \leftarrow 0; \Delta^* \leftarrow 0$
 22. RETURN $n^*, p^* = q(n^*) \cdot \Delta^*$

算法的 1-2 行初始化了循环所需的临时变量, 3-5 行建立了空小根堆用于存储数据购买者的效用需求函数断点. 6-17 行是算法的主体部分, 其中 8-11 行考察了所有断点的数值, 12-16 行考察了所有拐点的数值。

从以上分析中可以得出, 算法的时间复杂度为 $O(k)$, 其中 k 为断点的个数, 又因为 $k \leq n$, 所以算法的时间复杂度为 $O(n)$ 。

4 数学实验

4.1 实验设置

为了全方位考察保护隐私的数据市场机制, 本次实验使用 YEARMSD 和 MINST 数据集模拟数据

拥有者拥有的数据, 模拟数据拥有者和服务提供者在数据出售阶段的博弈。各个数据集的详细信息如下表 1 所示:

Table 1 数据集详细信息

数据集	训练方案	训练集大小	测试集大小
YearMSD	线性回归	386609	128836
MINST	深度学习	60000	10000

为定量模拟数据拥有者和服务提供者在数据购买与模型训练阶段的博弈, 本次实验考察了不同噪声添加下的数据所训练的模型质量, 定量考察隐私保护与模型质量之间的关系, 并进行函数拟合, 结果如图 2 和 3 所示:

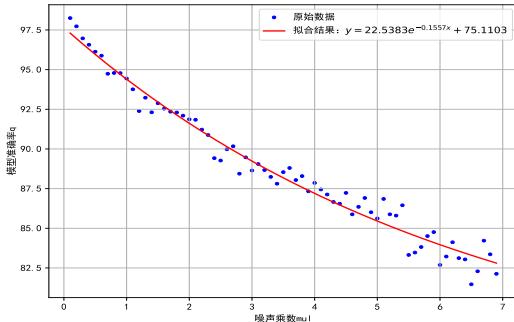


Fig. 2 MINST 模型质量与噪声乘量

首先考察图 2, 图中横轴为训练用数据所添加的噪声乘量 mul , mul 越高, 说明数据所添加的扰动强度越高, 数据的隐私保护效果越好。纵轴为训练出来的模型质量, 评判标准为准确率, 单位为 1%。可以看到, 随着噪声增强, 模型的质量逐步下降, 准确率从最初的 97.5% 下降到 82.5%, 说明隐私保护与模型质量不可兼得。同时注意到质量-噪声函数总体呈现下凸函数形, 随着噪声的增加, 准确率下降的速度越来越慢。是因为噪声具有边际效益递减特性: 已添加的噪声越多, 添加同样的噪声对模型的影响程度越来越小。

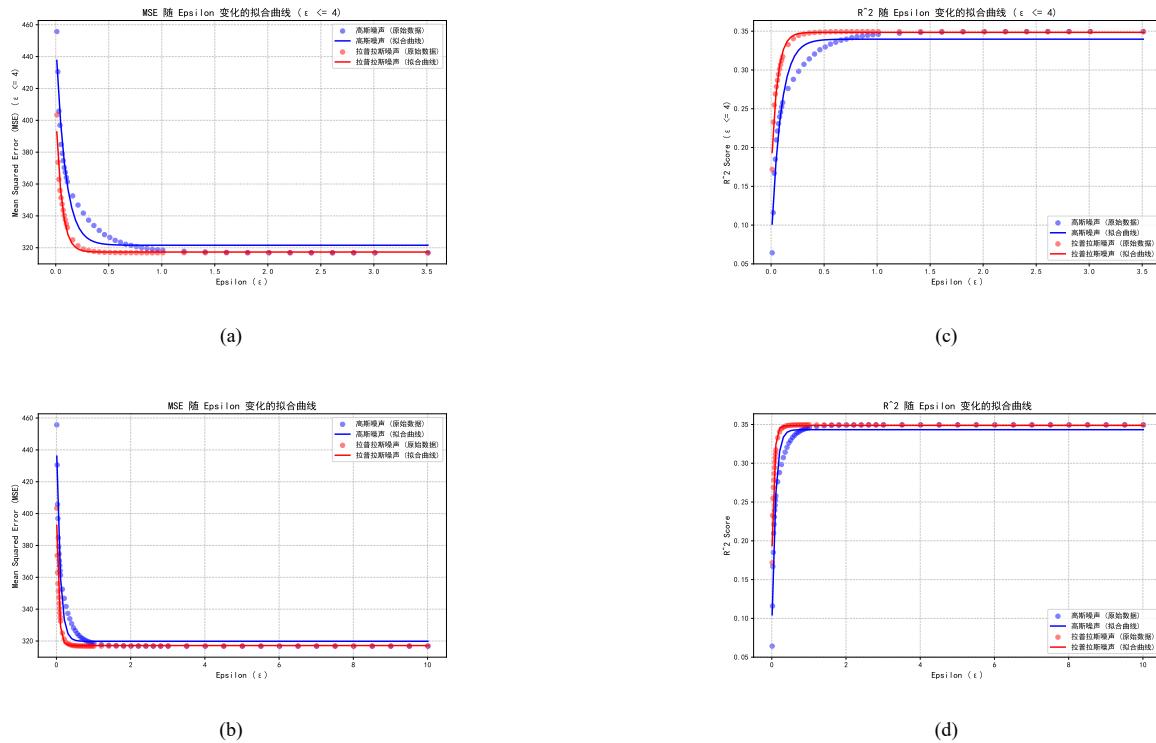


Fig. 1 跨栏图片示例

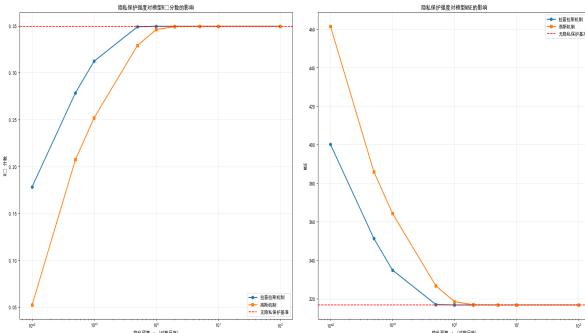


Fig. 3 YearPredictionMSD 模型质量与噪声系数

同时我们还使用后验考察了 YearPredictionMSD 模型质量与噪声系数的关系, 见图 3, 实验使用高斯差分技术, 图中横轴为训练用数据所添加的噪声乘量 ϵ 的对数值, ϵ 越低, 说明差分隐私的保护越严格, 数据所添加的扰动强度越高, 数据的隐私保护效果越好。纵轴为训练出来的模型质量, 其中左子图纵轴为 R^2 分数, R^2 分数越高, 说明模型准确率越低, 质量越差, 右子图为 MSE 分数, MSE 分

数, 说明模型质量越好。可以看到, 随着噪声增强, 模型的质量逐步下降。

4.1.1 对比方案

实验引入了贪心策略、无质疑策略等策略, 并给出它们的伪代码, 作为实验的对比机制。

服务提供者购买数据后, 将用 YEARMSD 和 POWER 数据集训练线性回归模型, 使用 SUSY 训练逻辑回归模型, MINST 数据集训练深度学习网络的识图模型。

服务购买者将根据模型的质量和自己的效益函数, 购买预测服务。

4.2 数据交易模拟实验结果

4.2.1 案例说明

在深度学习模型的实验中, 假定数据购买方的有 5 类, 购买方的收益函数为 $f = a_j \cdot (1 - e^{-b_j \cdot x})$, $0 < j < 6$ 。其中 x 为模型质量, a_i 均服从 $(50, 100)$ 的均匀分布, b_j 均服从 $(0.5, 1.5)$ 的均匀分布。根据前述实验拟合所得的质量函数为 $0.884 - 0.59 \cdot e^{-0.114 \cdot x}$,

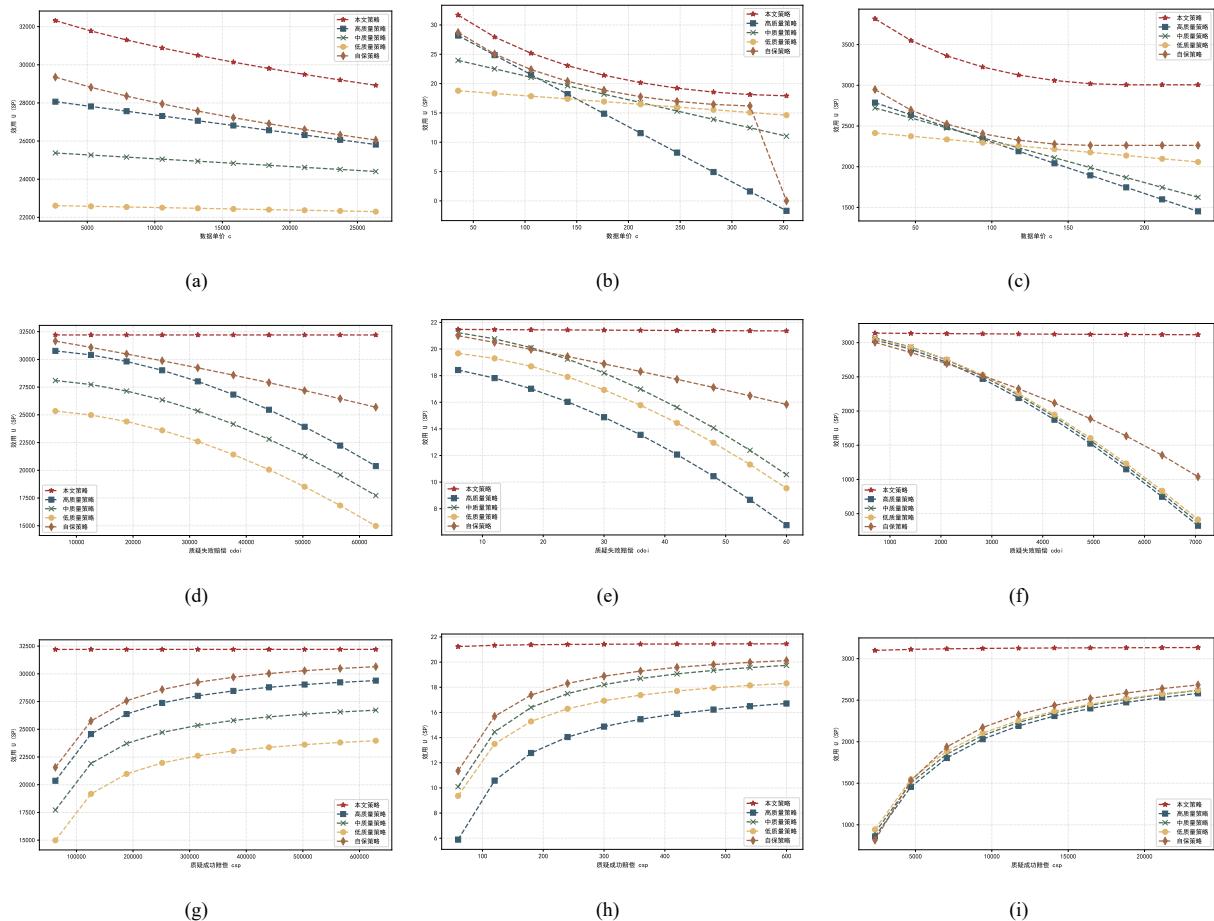


Fig. 4 跨栏图片示例

其中 x 为隐私扰动强度。

4.2.2 效益评估

下面考察深度学习模型的实验结果，其中使用深度学习计算的实验结果详见 6，其中横轴为出售者的隐私敏感度，纵轴为服务提供者的收益图。图中可以看出，出售者用户隐私敏感度的增加，购买数据的成本急剧上升，传统的最高成本策略所获得的收益很快就不足以支付购买成本，净利润成为了负值。说明在数据市场中需要

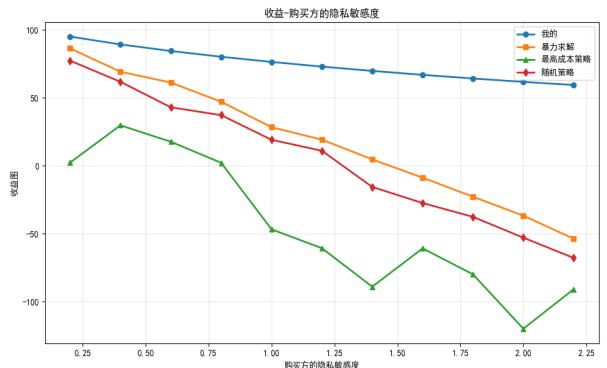


Fig. 6 MINST 模型质量与噪声乘量

4.2.3 模型准确率评估

我们采取了以下三个指标作为实验的测量指标：

- (1) 数据拥有者的诚信程度。
- (2) 服务提供者的总收益。

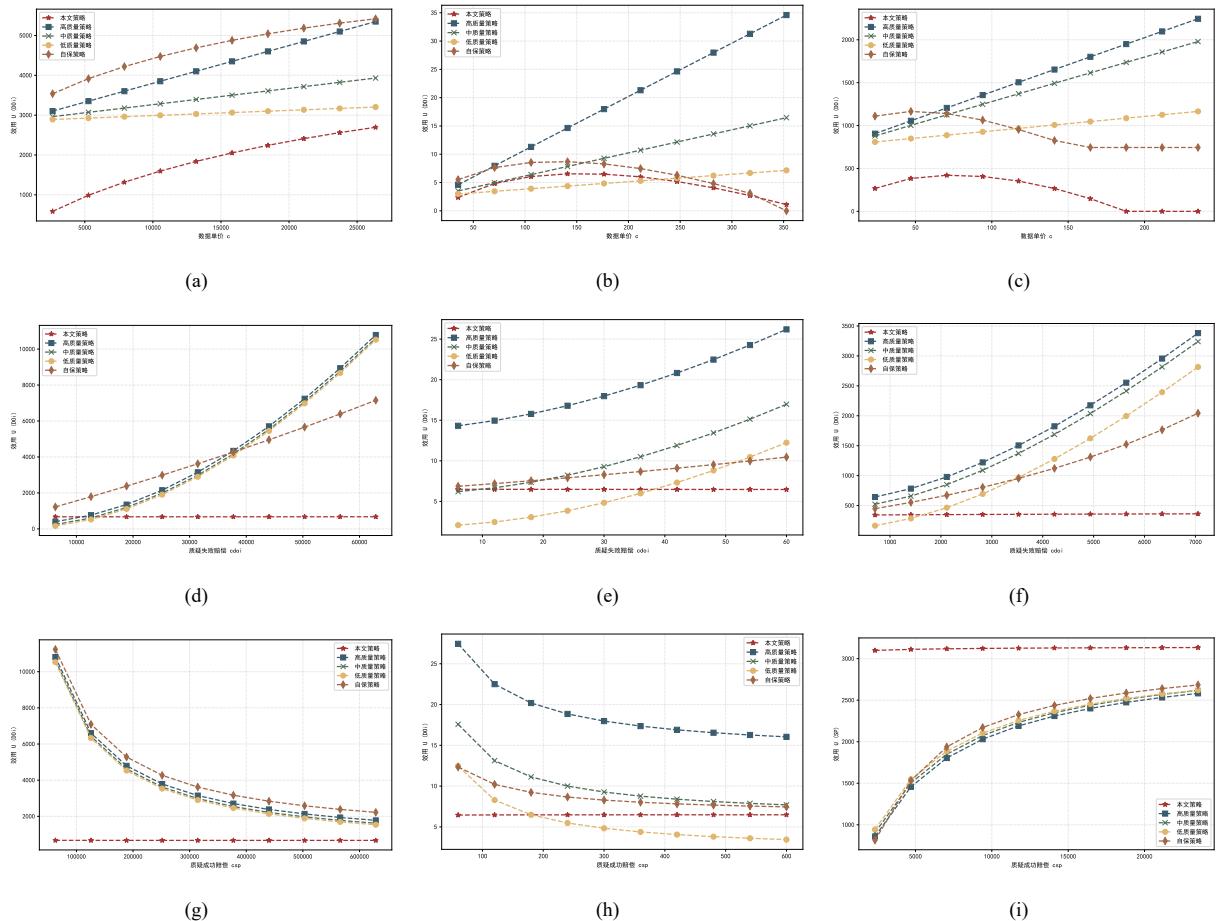


Fig. 5 跨栏图片示例

(3) 服务的预测准确度, 即服务质量。

5 一级标题 * 字体为 4 号黑体 * 标题 1

这是一个 CTEX 的 utf-8 编码例子, 这里是楷体显示, 这里是宋体显示, 这里是黑体显示, 这里是仿宋显示。另外一种方式: 这是楷体显示, *but* 英文和数字是斜体 *abcABC123*, 这是黑体显示 **abcACB123**, 这是仿宋显示 **abcABC123**。

5.1 关于数学部分

数学、中英文皆可以混排。You can intersperse math, Chinese and English (Latin script) without adding extra environments.

5.2 对投稿的基本要求

(1) 研究性论文主体应包括引言 (重点论述研究的科学问题、意义、解决思路、价值、贡献等)、相关工作 (为与引言部分独立的一个章节)、主要成果



Fig. 7 图片说明 * 字体为小 5 号, 图片应为黑白图, 图中的子图要有子图说明 *



Fig. 8 This is a picture.

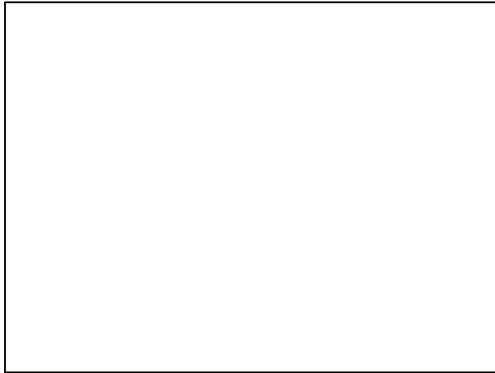


Fig. 9 第一个图片

论述、关键实现技术、验证(对比实验或理论证明)、结论(结束语)等内容;系统实现或实验应有关键点的详细论述,以便读者能够重复实现论文所述成果。实验应有具体的实验环境设置、全面细致的数据对比分析。

(2) 综述应包括引言、问题与挑战、研究现状分析、未来研究方向、结论等内容。以分析、对比为主,避免堆砌文献或一般性介绍、叙述。

(3) 定理证明、公式推导、大篇幅的数学论述、原始数据,放到论文最后的附录中。

稿件提交时的基本要求:

- (1) 本模板中要求的各项内容正确齐全,无遗漏;
- (2) 语句通顺,无中文、英文语法错误,易于阅

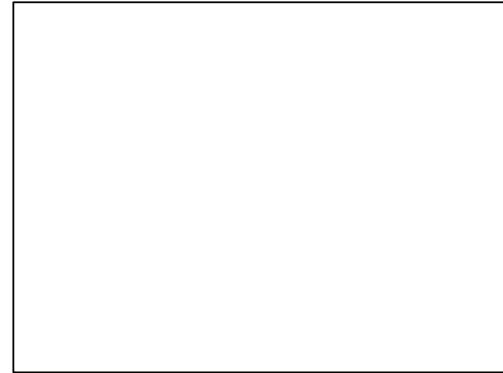


Fig. 10 第二个图片

读理解,符号使用正确,图、表清晰无误;

(3) 在学术、技术上,论文内容正确无误,各项内容确定。

5.3 二级标题 * 字体为 5 号黑体 * 标题 2

5.3.1 三级标题 * 字体为 5 号宋体 * 标题 3

* 正文部分,字体为 5 号宋体 * 正文文字

正文文字要求语句通顺,无语法错误,结构合理,条理清楚,不影响审稿人、读者阅读理解全文内容。以下几类问题请作者们特别注意:

- 1) 文章题目应明确反映文章的思想和方法;文字流畅,表述清楚;
- 2) 中文文字、英文表达无语法错误;

- 3) 公式中无符号、表达式的疏漏, 没有同一个符号表示两种意思的情况;
- 4) 数学中使用的符号、函数名用斜体;
- 5) 使用的量符合法定计量单位标准;
- 6) 矢量为黑体, 标量为白体;
- 7) 变量或表示变化的量用斜体;
- 8) 图表规范, 量、线、序无误, 位置正确(图表必须在正文中有所表述后出现, 即...如图 1 所示)(注意纵、横坐标应有坐标名称和刻度值)。
- 9) 列出的参考文献必须在文中按顺序引用, 即参考文献顺序与引用顺序一致, 各项信息齐全(格式见参考文献部分);
- 10) 首次出现的缩写需写明全称, 首次出现的符号需作出解释。

11) 图的图例说明、坐标说明全部用中文或量符号。

12) 图应为矢量图。

- 13) 表中表头文字采用中文。
- 14) 公式尺寸:
- 标准: 10.5 磅
- 下标/上标: 5.8 磅
- 次下标/上标: 4.5 磅
- 符号: 16 磅
- 次符号: 10.5 磅
- 15) 组合单位采用标准格式, 如: “ $\text{pJ}/\text{bit}/\text{m}^4$ ” 应为 “ $\text{pJ}/(\text{bit}\cdot\text{m}^4)$ ”

定理 1. *****. * 定理内容.*

[“定义”、“假设”、“公理”、“引理”等的排版格式与此相同, 详细定理证明、公式可放在附录中]

证明. * 证明过程.* [“例 x”等的排版格式相同]

证毕.

图 X 图片说明 * 字体为小 5 号, 图片应为黑白图, 图中的子图要有子图说明 *

表 X 表说明 * 表说明采用黑体 *

* 示例表格 * * 第 1 行为表头, 表头要有内容 *

过程 X. 过程名称

*《计算机学报》的方法过程描述字体为小 5 号宋体, IF、THEN 等伪代码关键词全部用大写字母, 变量和函数名称用斜体 *

算法 Y. 算法名称.

输入:

输出:

*《计算机学报》的算法描述字体为小 5 号宋体, IF、THEN 等伪代码关键词全部用大写字母, 变量和函数名称用斜体 *

5.3.2 参考文献

这是参考文献示例。参考文献应遵循 GB/T 7741-2015 标准。引用文献 1^[2], 文献 2^[3], 文献 3-5^[4-6]。

致 谢 * 致谢内容.* 致谢

参 考 文 献

- [1] 叶青青, 孟小峰, 朱敏杰, 等. 本地化差分隐私研究综述 [J]. 软件学报, 2018, 第 29 卷(第 7 期): 1981-2005.
- [2] ボハンデ. 過去及び現在に於ける英國と会[J]. 日本時報, 1928, 17: 5-9.
- [3] 陈晋镳, 张惠民, 朱士兴, 等. 蓟县震旦亚界研究[M]//中国地质科学院天津地质矿产研究所. 中国震旦亚界. 天津: 天津科学技术出版社, 1980: 56-114.
- [4] BRAVO H, OLAVARRIA J. Comparative study of visual inter and intrahemispheric cortico-cortical connections in five native chilean rodents[J]. Anatomy and embryology, 1990, 181(1): 67-73.
- [5] 牛志明, 斯温兰德, 雷光春. 综合湿地管理国际研讨会论文集[C]. 北京: 海洋出版社, 2013.

- [6] 袁训来, 陈哲, 肖书海. 蓝田生物群: 一个认识多细胞生物起源和早期演化的新窗口 – 篇一[J]. 科学通报, 2012, 57(34): 3219.

附录 X.

* 附录内容置于此处, 字体为小 5 号宋体。附录内容包括: 详细的定理证明、公式推导、原始数据等 *



First A. Author * 计算机学报第 1 作者提供照片电子图片, 尺寸为 1 寸。英文作者介绍内容包括: 出生年, 学位(或目前学历), 职称, 主要研究领域(与中文作者介绍中的研究方向一致)。* * 字体为小 5 号 Times New Roman*



Second B. Author * 英文作者介绍内容包括: 出生年, 学位(或目前学历), 职称, 主要研究领域(与中文作者介绍中的研究方向一致)。* * 字体为小 5 号 Times New Roman*

Background

* 论文背景介绍为英文, 字体为小 5 号 Times New Roman 体 *

论文后面为 400 单词左右的英文背景介绍。介绍的内容包括:

本文研究的问题属于哪一个领域的什么问题。该类问题目前国际上解决到什么程度。

本文将问题解决到什么程度。

课题所属的项目。

项目的意义。

本研究群体以往在这个方向上的研究成果。

本文的成果是解决大课题中的哪一部分, 如果涉及 863\973 以及其项目、基金、研究计划, 注意这些项目的英文名称应书写正确。